

ガヤボイスTTS 実戦投入ガイド

9モデル × 161セリフの実測ベンチから要点だけ | 2026-08 | 聴き比べ: gaya-bench.pages.dev

1. 声の作り方は3方式 — 「何を入力するか」が違う

プリセット話者型	参照音声クローン型	テキスト指示型
入力: セリフ + 声とスタイルの選択 例: 「コハク」×「ささやき」で『いらっしやいませ』 声はモデル付属のものから選ぶだけ。安定・高速だが声の種類は増やせない	入力: セリフ + 見本音声 (5~10秒) 例: 女性声優の収録WAVを渡すとその声質で『いらっしやいませ』 見本の声・演技を写し取る。見本の品質と権利がすべて	入力: セリフ + 声の説明文 例: 「低く落ち着いた中年男性の声」と書く → その声で話してくれる 見本音声いらずで自由度最大。ただし指示への従い方に癖がある

2. モデル早見表 (実測所感)

モデル	方式	強み	弱み・注意
AivisSpeech コハク	プリセット	日本語アクセントが最も安定。読みを直接指定できる	声は1話者+数スタイルのみ
Supertonic 3	プリセット	圧倒的に高速 (量産・リアルタイム向き)	日本語が早口になる癖。表現の幅は狭い
Chatterbox V3	クローン	感情の誇張度を数値で制御できる	日本語で声質崩壊・誤読が出やすい
CosyVoice 3	クローン	指示文と読み指定を併用でき、平均点が安定	同一条件でも毎回変わる (数打ち前提)
GPT-SoVITS v2ProPlus	クローン	数分の音声で追加学習可 — 自社収録と組む本命	見本の切り出し品質に敏感
Irodori-TTS v3	テキスト指示	日本語特化。声質の文章指定がよく効く	演技過剰気味。長い指示で男性役が崩れる
Irodori-TTS v4	指示+見本	v3の男性声問題が改善。見本は計120秒まで連結可	公開直後 (2026年)。実績蓄積中
Qwen3-TTS	テキスト指示	感情・話し方の指示語彙が豊富	声の同一性が揺れる — 役ごとの固定アンカー必須
VoxCPM2	テキスト指示	人外 (精霊・ゴブリン・機械) の声設計が得意	取れ高の音質ばらつきが大きい

全モデル完全ローカル動作 (GPU 12GB 1枚で確認)・生成物商用可の条件で選定。ライセンス詳細はサイトのクレジット参照。

2b. 各モデルが受け付ける入力要素 (公開データと同一の真値)

モデル	感情の指示	声質の説明文	見本音声	非言語音	読み仮名指定
AivisSpeech コハク	○	—	—	—	○
Supertonic 3	—	—	—	—	○
Chatterbox V3	○	—	○	—	—
CosyVoice 3	○	—	○	—	○
GPT-SoVITS v2ProPlus	—	—	○	—	○
Irodori-TTS v3	○	○	○	○	○
Irodori-TTS v4	○	○	○	○	—
Qwen3-TTS	—	○	○	—	—
VoxCPM2	○	○	○	—	○

○=対応。感情の指示=感情や強度を指定できる / 声質の説明文=文章で声を作る / 見本音声=クローン元を渡せる / 非言語音=笑い・ため息などの表現指示 / 読み仮名指定=漢字の読みを指定できる。

3. 量産パイプライン — 5段で回す

1	台本の構造化	セリフごとに役柄情報 (性別・年齢・声質・感情・強度) をデータで付与する
2	役の声を固定	クローン型は見本を役に割当。指示型は役ごとにアンカー音声を先に1つ確定し全セリフで使い回す — 感情ごとに変わると別人の声になる
3	数打ち生成	1セリフにつき別シードで3~4テイク。合格3本たまるまで追加
4	自動チェック	音量統一 → 音声認識で読み合わせ (誤読検出) → 声の高さで性別検査
5	人手は最後だけ	疑義フラグ付きのテイクだけ聴いて選ぶ。全量聴取は不要 (161セリフ×9モデルで実証済み)

4. チューニングのコツ

- クローン型は見本が品質の9割。5~10秒・雑音なし・目的の演技トーンに近い素材を。権利クリーンな公開素材は少なく、量産の本命は声優と契約した自社収録 (収録指示書はモデルの入力要件から自動生成できる設計済み)。
- 指示型の説明文は「短く・固定・必須情報のみ」。形容を盛るほど従わなくなる (男性役が女性声化した根本原因)。セリフごとに変えてよいのは感情・演技の指示だけ。
- 誤読は曖昧語だけ読み仮名指定 (例:「辛(つら)い」)。全文を仮名にするとアクセントが崩れ、外国人風の平板な発音になる。
- 全テイクの生成条件 (シード・パラメータ・見本) を記録。当たりテイクの再現・差し替えができる。

5. 注意事項 — これだけは外さない

- 権利は「モデル・生成物・見本音声」の3層で別。モデルが商用可でも見本の権利は別途必要。他社TTSの出力を見本や学習に流用するのは規約違反の場合あり。実在人物の声の無断模倣は全モデルで禁止 — 架空キャラ用途に限定。
- 一部モデルは出力に不可聴の電子透かしを自動で埋め込む (Irodori系・Chatterbox)。納品要件と事前に照合を。
- 「渡したつもり」を信用しない。役柄条件が実際にモデルへ渡ったかは別問題 (本ベンチでも公開後に伝達バグを2系統発見し全量再生成)。実際に使われた条件の記録を成果物とセットで保存し、機械検証できる形で検収する。

出典: gaya-bench 実測

(15場面161セリフ×9モデル、公開1,449音声+検証用数千テイク)。品質注記は自動判定・人手確認は順次。根拠はリポジトリ docs/research/ と各Issueに記録。