

ガヤボイスTTS 実戦投入ガイド

モブNPCの環境ボイスをTTSで量産するための実測知見 | 2026-08 | 聴き比べサイト: gaya-bench.pages.dev

9

モデル

15

場面 (酒場・戦場など)

161

セリフ×全モデル

1,449

公開音声

12GB

GPU 1枚で全て動作

1 声の作り方は3方式 「何を入力するか」が違う

プリセット話者型

入力: セリフ + 声とスタイルの選択
例: 「コハク」×「ささやき」を選ぶ
→ その声でセリフを読む

付属の声から選ぶだけ。安定・高速。
声の種類は増やせない

参照音声クローン型

入力: セリフ + 見本音声 (必須・5~10秒)

例: 女性声優の収録WAVを渡す
→ その声質でセリフを読む

見本の声・演技を写し取る。見本の品質と権利がすべて

テキスト指示型

入力: セリフ + 声の説明文 (見本は任意)

例: 「低く落ち着いた中年男性の声」と書く
→ その声でセリフを読む

見本がなくても声を作れるのが本質。
見本を渡せばクローンも可 (下表○)

2 モデル早見表と対応入力 ○の判定は公開サイトと同一データ

モデル	主方式	強み	弱み・注意	感情	声質文	見本	非言語	読み
AivisSpeech コハク	プリセット	日本語アクセント最安定。読みを直接指定可	声は1話者+数スタイルのみ	○	—	—	—	○
Supertonic 3	プリセット	圧倒的に高速 (量産・リアルタイム向き)	日本語が早口になる癖。表現の幅は狭い	—	—	—	—	○
Chatterbox V3	クローン	感情の誇張度を数値で制御できる	日本語で声質崩壊・誤読が出やすい	○	—	○	—	—
CosyVoice 3	クローン	指示文と読み指定を併用でき安定	同一条件でも毎回変わる (数打ち前提)	○	—	○	—	○
GPT-SoVITS v2ProPlus	クローン	数分の音声で追加学習可 — 自社収録と組む本命	見本の切り出し品質に敏感	—	—	○	—	○
Irodori-TTS v3	テキスト指示	日本語特化。声質の文章指定がよく効く	演技過剰気味。長い指示で男性役が崩れる	○	○	○	○	○
Irodori-TTS v4	テキスト指示	v3の男性声問題が改善。見本対応が最強 (計120秒連結可)	公開直後 (2026年)。実績蓄積中	○	○	○	○	—
Qwen3-TTS	テキスト指示	説明文で話し方・感情まで細かく書ける	声の同一性が揺れる — 役ごとアンカー必須	—	○	○	—	—
VoxCPM2	テキスト指示	人外 (精霊・機械など) の声設計が得意	取れ高の音質ばらつきが大きい	○	○	○	—	○

主方式=本ベンチで各役の声を決めた方法。右5列=それとは別に、モデルが受け付けられる入力の一覧 (○=対応): 感情=専用の感情・強度指定 (説明文に書く方式は含まず) / 声質文=文章で声を作る / 見本=見本音声からのクローン / 非言語=笑い・ため息等 / 読み=漢字の読み指定。テキスト指示型の多くは見本にも対応 — つまり方式は排他ではなく、見本○のモデルはクローン型としても使える。全モデル生成物商用可の条件で選定 (詳細はサイトのクレジット)。

3 台本は「構造化」して持つ これが全モデルへの入力の源泉になる

```
# scenarios/village-morning.yaml (公開データの実物・抜粋)
characters:
  - id: granny
    gender: female age: elderly # 「声の印象」として指定
    voice: しわがれた高めの声。ゆっくりとした丁寧な口調。 # → 声質説明文・見本選びの材料
lines:
  - character: granny
    text: 腰が痛うてかなわんわ…… # セリフ本文
    emotion: pain intensity: 2 # 12感情×強さ1〜3 → 演技指示へ変換
    delivery: 腰を叩きながらのぼやき。語尾が伸びて消える。 # 演出意図
    final_intonation: fall # 語尾を上げない (カタコト化の検査に使用)
```

ポイント: 台本を最初からこの形式で書けば、モデルを乗り換えても台本は書き直さない。方式ごとの入力(説明文・見本選択・演技指示)は各フィールドから機械的に組み立てられる。誤読しやすい語だけ読み仮名フィールドを足す。

4 量産パイプライン 5段で回す — 人手は最後だけ

1	台本の構造化	上記YAML形式。役柄・感情・演出をデータで持つ
2	役の声を固定	クローン型は見本を役に割当。指示型は役ごとに一度生成した声(アンカー音声)を自作の見本として固定し、全セリフで使い回す — 感情ごとに変わると別人の声になる(実測)
3	数打ち生成	1セリフ3〜4テイクを別シードで。合格3本たまるまで追加
4	自動チェック	音量統一 → 音声認識で読み合わせ(誤読検出) → 声の高さで性別検査
5	人手選抜	疑義フラグ付きだけ聴く。全量聴取は不要(161セリフ×9モデルで実証済み)

5 チューニングの勘所 実測で確定した運用則

- ◆ クローン型は見本が品質の9割。5〜10秒・雑音なし・目的の演技トーンに近い素材を。権利クリーンな公開素材は少なく、量産の本命は声優と契約した自社収録(収録指示書はモデル入力要件から自動生成できる設計済み)。
- ◆ 指示型の声質説明文は「短く・固定・必須情報のみ」。良い例:「若い成人の男性。低く落ち着いた男性の声。」／悪い例:形容を重ねた長文 — 従わなくなり男性役が女性声になる実測あり。セリフごとに変わるのは感情・演技の指示だけ。
- ◆ 誤読は曖昧語だけ読み仮名指定(例: 辛い→「つらい」)。全文を仮名化してはいけない — アクセント情報が失われ、外国人風の平板な発音になる。
- ◆ 全テイクの生成条件(シード・パラメータ・見本)を記録し、当たりテイクを再現・差し替えできる状態を保つ。

6 注意事項 契約・納品の前に必ず確認

- ◆ 権利は「モデル・生成物・見本音声」の3層で別。モデルが商用可でも見本の権利は別途必要。他社TTSの出力を見本・学習に流用するのは規約違反の場合あり。実在人物の声の無断模倣は全モデルで禁止 — 架空キャラ用途に限定。
- ◆ 一部モデル(Irodori系・Chatterbox)は不可聴の電子透かしを出力へ自動埋込。納品要件・音声加工フローと事前に照合を。
- ◆ 「渡したつもり」を信用しない。役柄条件が実際にモデルへ渡ったかは別問題(本ベンチも公開後に伝達バグを2系統発見し全量再生成)。実際に使われた条件の記録を成果物とセットで保存・検収する。

出典: gaya-bench 実測(15場面161セリフ×9モデル)。品質注記は自動判定・人手確認は順次。根拠はリポジトリ docs/research/ と各Issueに記録。