

Chatterbox Multilingual V3

クローン型

感情の誇張度を数値制御できるクローン型。日本語では荒れやすく選抜前提

実測ピーク 4.0GB
VRAM

中速
速度

PerTh自動埋込
透かし

1 0からのセットアップと試し生成 公式配布物のみで完結

- ◆ 公式pipパッケージ1つで完結。重み (ResembleAI/chatterbox) は初回自動DL
- ◆ 見本音声 (5~10秒・雑音なしのWAV) を1つ用意する

```
pip install chatterbox-tts
# Python
import torchaudio as ta
from chatterbox.mtl_tts import ChatterboxMultilingualTTS
m = ChatterboxMultilingualTTS.from_pretrained(device="cuda", t3_model="v3")
wav = m.generate("いらっしゃいませ！", language_id="ja",
    audio_prompt_path="voice.wav", exaggeration=0.5, cfg_weight=0.5)
ta.save("out.wav", wav, m.sr)
```

2 入力の用意 このモデルに何を渡すか

- ◆ 見本音声 (audio_prompt_path) が声質のすべて。目的の演技トーンに近い5~10秒を役ごとに1つ固定
- ◆ language_id="ja" を必ず明示 — 多言語モデルのため、落とすと英語訛りになる

3 最適化アドバイス 実測で効いた順

- ◆ exaggeration (感情誇張。控えめ0.4~派手0.8目安) と cfg_weight (0.5) が主ノブ。上げるほど演技は派手だが崩壊率も上がる
- ◆ 日本語では声質崩壊・棒読み化・誤読が一定率で発生 (実測)。シードを変えた複数生成+聴き比べで選ぶ前提
- ◆ 悪化時はパラメータより先に見本を疑う (無音・残響・トーン不一致)

4 本ベンチでの成績 gaya-bench.pages.dev で全音声を試聴可

- ◆ 公開161/161行 (自動選抜)。日本語での声線崩壊・誤読は診断継続中 — 公開版にも品質注記バッジあり
- ◆ 同一見本でも台詞により崩れ方が変わることを確認。数打ち選抜の効果が最も大きいモデル

VRAM・成績などの数値は gaya-bench (gaya-bench.pages.dev) の公開1,449音声とその生成記録による実測値。量産パイプライン全体と権利・透かしの注意は docs/production-adoption-guide.pdf を参照。