

CosyVoice 3 (0.5B)

クローン型

指示文と読み指定を併用できるクローン型。平均点が安定、ただし非決定

実測ピーク 5.3GB
VRAM

中速
速度

同条件でも毎回変わる
性質

1 0からのセットアップと試し生成 公式配布物のみで完結

- ◆ 公式リポジトリをclone (--recursive必須) し requirements を導入 (公式はPython 3.10のconda/venv)
- ◆ 重み (Fun-CosyVoice3-0.5B-2512) を HuggingFace / ModelScope からDL

```
git clone --recursive https://github.com/FunAudioLLM/CosyVoice.git; cd CosyVoice
pip install -r requirements.txt
# Python — 重みDL→ zero-shot クローン
from huggingface_hub import snapshot_download
snapshot_download('FunAudioLLM/Fun-CosyVoice3-0.5B-2512', local_dir='pretrained_models/cv3')
from cosyvoice.cli.cosyvoice import AutoModel; import torchaudio
cosy = AutoModel(model_dir='pretrained_models/cv3')
for i, j in enumerate(cosy.inference_zero_shot('いらっしやいませ!',
'見本音声の書き起こし<[endofprompt]>', 'voice.wav', stream=False)):
    torchaudio.save(f'out_{i}.wav', j['tts_speech'], cosy.sample_rate)
```

2 入力の用意 このモデルに何を渡すか

- ◆ 見本音声 + prompt文の二段構え。prompt先頭の指示文 (「怒って強く」等の短い日本語) で感情・話し方を足せる (inference_instruct2)
- ◆ 読みはかな表記で明示可能 — 誤読しやすい語だけかな指定 (全文かな化はアクセント崩れの元)

3 最適化アドバイス 実測で効いた順

- ◆ seedを固定しても出力が毎回変わる (非決定) — 再現性は期待せず、複数生成から選抜する前提で回す
- ◆ speed引数あり。fp16で十分な品質
- ◆ 指示文を長くしても効果は頭打ち。感情は「指示文+見本のトーン」の組合せで作る方が効く

4 本ベンチでの成績 gaya-bench.pages.dev で全音声を試聴可

- ◆ 公開161/161行。初回ランの生成失敗2行は再生成で解消
- ◆ 同一seed・同一入力で出力が変わる非決定性を実測で確認済み (生成順の影響ではない)

VRAM・成績などの数値は gaya-bench (gaya-bench.pages.dev) の公開1,449音声とその生成記録による実測値。量産パイプライン全体と権利・透かしの注意は docs/production-adoption-guide.pdf を参照。