

Irodori-TTS v3 (600M VoiceDesign)

テキスト指示型

日本語特化のテキスト指示型。声質の文章指定がよく効くが、指示文設計に規律が要る

実測ピーク 6.0GB
VRAM

中速
速度

SilentCipher自動埋込
透かし

1 0からのセットアップと試し生成 公式配布物のみで完結

- ◆ 公式リポジトリ (Aratako/Irodori-TTS) をcloneし、uv で環境同期 (CUDAバージョン別のextraあり)
- ◆ 重み・日本語コーデックは初回に HuggingFace から自動DL

```
git clone https://github.com/Aratako/Irodori-TTS.git; cd Irodori-TTS
uv sync --extra cu128 # CUDA 12.8の場合。READMEのextra一覧参照
uv run --no-sync python infer.py `
  --hf-checkpoint Aratako/Irodori-TTS-600M-v3-VoiceDesign `
  --text "いらっしやいませ！" --no-ref `
  --caption "若い女性。明るく張りのある声。" --output-wav out.wav
```

2 入力の用意 このモデルに何を渡すか

- ◆ caption (声の説明文): 性別・年齢・声質を必須情報として短く列挙。形容を盛った長文は禁止 — 男性役が女性声化する実測根因
- ◆ 台詞ごとに変えるのは感情表現だけ。役の声を固定したいときは、一度生成した音声を見本 (--ref-wav) にして使い回す
- ◆ 読み指定に対応。誤読語のみ最小指定

3 最適化アドバイス 実測で効いた順

- ◆ cfg / num_steps が品質ノブ。stepsを下げると速いが子音が甘くなる
- ◆ 演技過剰・母音伸びの傾向 (実測)。落ち着いた台詞はcaptionの感情表現を一段弱めると自然
- ◆ seed固定で決定論的 — 数打ちはseed違いで。崩れたらcaption短縮→見本固定の順で直す

4 本ベンチでの成績 gaya-bench.pages.dev で全音声を試聴可

- ◆ 公開161/161行。当初は長captionで男性27役中10役が女性声化 → caption短縮で解決 (男性役median F0 180Hz超→110~155Hz)
- ◆ 演技過剰傾向は聴取で確認。全体設定の変更はブラインド比較で棄却し、台詞単位の調整で対応

VRAM・成績などの数値は gaya-bench (gaya-bench.pages.dev) の公開1,449音声とその生成記録による実測値。量産パイプライン全体と権利・透かしの注意は docs/production-adoption-guide.pdf を参照。