

Irodori-TTS v4-Small (766M)

テキスト指示型

caption生成とクローンの統一モデル。v3の男性声問題が改善、見本対応が最強 (計120秒)

実測ピーク 4.0GB
VRAM

実測RTF 0.60
速度

SilentCipher自動埋込
透かし

1 0からのセットアップと試し生成 公式配布物のみで完結

- ◆ セットアップはv3と同じ公式リポジトリ。checkpoint名を v4-Small に変えるだけ
- ◆ Windowsは FFmpeg共有ライブラリ版 が必要 (依存のtorchcodecが要求。winget: Gyan.FFmpeg.Shared → binをPATHへ)

```
git clone https://github.com/Aratako/Irodori-TTS.git; cd Irodori-TTS
uv sync --extra cu128
uv run --no-sync python infer.py `
  --hf-checkpoint Aratako/Irodori-TTS-v4-Small `
  --text "いらっしやいませ！" --ref-wav voice.wav `
  --caption "明るく張りのある接客の声。" --output-wav out.wav
# 見本なし生成は --ref-wav の代わりに --no-ref
```

2 入力の用意 このモデルに何を渡すか

- ◆ captionはv3と同じ規律 (短く・固定・必須情報のみ)。v4は男性役の遵守が大きく改善 (実測53役全て機械検査合格)
- ◆ 見本音声は複数クリップを合計120秒まで連結可能 — 長い見本ほどクローンが安定する設計。単発5秒だけならv3系より弱い

3 最適化アドバイス 実測で効いた順

- ◆ num_steps 40 / cfg (caption・text別スケール) が既定で安定
- ◆ クローン品質を上げたいときは見本を足して長くするのが第一手 (パラメータ調整より効く)
- ◆ 読み指定は非対応 — 誤読はセリフの表記側で回避 (かな交じり表記など)

4 本ベンチでの成績 gaya-bench.pages.dev で全音声を試聴可

- ◆ 公開161/161行・品質注記0件。役の声53件が修正済み検査で一発全役合格 (v3は26役が要再試行だった)
- ◆ 644テイクの量産ランを完走 (音声時間加重RTF 0.596)。現時点で総合最有力の一角

VRAM・成績などの数値は gaya-bench (gaya-bench.pages.dev) の公開1,449音声とその生成記録による実測値。量産パイプライン全体と権利・透かしの注意は docs/production-adoption-guide.pdf を参照。