

Qwen3-TTS (12Hz 1.7B)

テキスト指示型

説明文で話し方まで細かく書ける多言語モデル。声の固定運用が生命線

実測ピーク 5.8GB
VRAM

中速
速度

VoiceDesign+Baseの2段
構成

1 0からのセットアップと試し生成 公式配布物のみで完結

- ◆ 公式pipパッケージ1つで完結。VoiceDesign (声を作る) と Base (見本でクローン) の2モデル構成
- ◆ 重みは初回に HuggingFace から自動DL

```
pip install -U qwen-tts
# Python — ①説明文で声を生成 → ②その音声を見本にBaseで量産
import torch, soundfile as sf
from qwen_tts import Qwen3TTSTModel
m = Qwen3TTSTModel.from_pretrained("Qwen/Qwen3-TTS-12Hz-1.7B-VoiceDesign",
    device_map="cuda:0", dtype=torch.bfloat16)
wavs, sr = m.generate_voice_design(text="いらっしゃいませ！", language="Japanese",
    instruct="若い女性。明るく張りのある接客の声。")
sf.write("anchor.wav", wavs[0], sr)
# ②: Base model の generate_voice_clone(ref_audio="anchor.wav", ...) で全セリフ生成
```

2 入力の用意 このモデルに何を渡すか

- ◆ VoiceDesignで役の声を1回だけ作り、その音声をBaseの見本 (ref_audio+ref_text) にして全セリフを生成する2段運用が必須。台詞ごとに声を作り直すと別人化する (実測で確定した失敗パターン)
- ◆ 声の説明文 (instruct) には性別・年齢・役柄を必ず入れる。感情・話し方は台詞ごとの指示で変える

3 最適化アドバイス 実測で効いた順

- ◆ 感情ごとに見本を変えない — 話者同一性が崩れる。感情は指示文だけで付ける
- ◆ sampling系は既定で安定。荒れたらまず見本 (anchor) の質を疑い、作り直す
- ◆ 多言語混在の台詞に強い — 外国語訛りの役はこのモデルが第一候補

4 本ベンチでの成績 gaya-bench.pages.dev で全音声を試聴可

- ◆ 公開161/161行。旧実装に「見本を渡したつもりで破棄」のバグがあり、生成条件の記録検証で発見→修正した経緯あり
- ◆ 2段運用の確立後は話者同一性が安定。感情別見本の旧方式はブラインド評価で不採用

VRAM・成績などの数値は gaya-bench (gaya-bench.pages.dev) の公開1,449音声とその生成記録による実測値。量産パイプライン全体と権利・透かしの注意は docs/production-adoption-guide.pdf を参照。