

Qwen3-TTS (12Hz 1.7B)

テキスト指示型

説明文で話し方まで細かく書ける多言語モデル。声の固定運用が生命線

実測ピーク 5.8GB
VRAM

中速
速度

Base+VoiceDesignの2段
構成

1 用意するもの・セットアップ 0からローカルで試すまで

- ◆ extra qwen を同期。Base / VoiceDesign 両モデル (固定版) は初回自動DL

```
# リポジトリ取得〜1本試し生成 (Windows / PowerShell)
git clone git@github.com:Hitsuki-Ban/gaya-bench.git; cd gaya-bench
uv sync --project pipeline --locked --extra qwen
uv run --project pipeline --locked --extra qwen gaya gen `
  --model qwen3-tts-12hz-1.7b --scenario tavern-night --line barmaid-001 --takes 1 --seed-base 42
# → artifacts/takes/<run-id>/audio/ にWAV+Opus。重みは初回に固定版が自動DLされる
```

2 入力の用意 このモデルに何を渡すか

- ◆ VoiceDesignで役の声を1つ生成→その音声をBaseの見本として全セリフに使う2段運用が必須。台詞ごとにVoiceDesignし直すと別人化する (実測で確定した失敗パターン)
- ◆ 声の説明文には性別・年齢・種別・役柄を必ず入れる。感情・話し方は台詞ごとの指示文で変える

3 最適化アドバイス 実測で効いた順

- ◆ 感情ごとに見本を変えない — 話者同一性が崩れる。感情は指示文だけで付ける
- ◆ sampling (temperature系) は既定で安定。荒れたらまずアンカー音声の質を疑う
- ◆ 多言語混在台詞 (中華街シーン等) に強い — 外国語風の役はこのモデルが第一候補

4 本ベンチでの成績 gaya-bench.pages.dev で全音声を試聴可

- ◆ 公開161/161行。初期実装は見本を渡したつもりで破棄するバグがあり、条件レシート検証で発見→修正した経緯あり
- ◆ アンカー2段運用の確立後は話者同一性が安定。感情別に見本を変えた旧方式はブラインド評価で不採用

共通の量産手順 (数打ち→自動チェック→選抜) と権利・透かしの注意は docs/production-adoption-guide.pdf を参照。パラメータ実測値の出典は data/manifest.json (公開1,449音声のprovenance)。